

Chapitre 15

Statistiques

Faire des **statistiques**, c'est recueillir, organiser, synthétiser, représenter et exploiter des données, numériques ou non, dans un but de comparaison, de prévision, de constat...

Les plus gros "consommateurs" de statistiques sont les **assureurs** (risques d'accidents, de maladie des assurés), les **médecins** (épidémiologie), les **démographes** (populations et leur dynamique), les **économistes** (emploi, conjoncture économique), les **météorologues** ...

1 Définitions et vocabulaire des statistiques

Définition 1.1: Population, individu, caractère

La **population** est l'ensemble des individus sur lesquels portent l'étude statistique. (Par exemple classe de seconde, hommes, habitants de la France ...)

Le **caractère** d'une série statistique est une propriété étudiée sur chaque individu :

- ★ Lorsque le caractère ne prend que des valeurs numériques, il est **quantitatif** :
 - **discret** s'il ne peut prendre que des valeurs isolées (notes, âge ...)
 - **continu** dans le cas contraire (poids, taille ...). Dans ce cas on effectue souvent un regroupement des valeurs par **classes**.
- ★ Sinon, on dit qu'il est **qualitatif** (couleur des yeux, sport pratiqué ...) : les modalités ne sont pas des nombres.

Définition 1.2: Série statistique à caractère quantitatif, regroupement en classes

Une **série statistique à caractère quantitatif**, est une liste de N valeurs $x_1, x_2, \dots, x_N$.

- ★ Parmi cette série, on peut identifier les p valeurs différentes $y_1, y_2, \dots, y_p$ et les **effectifs** associés $n_1, n_2, \dots, n_p$ avec $n_1 + n_2 + \dots + n_p = N$.
- ★ On peut également définir q **classes** différentes $[y_1; y_2[, [y_2; y_3[, \dots, [y_{p-1}; y_p[$ et les **effectifs** associés $n_1, n_2, \dots, n_q$ avec $n_1 + n_2 + \dots + n_q = N$.

L'effectif est le nombre d'éléments de la série associées à une valeur y_i (ou une classe $[y_i; y_{i+1}[$).

Définition 1.3: Fréquence, pourcentage

Soit des effectifs $n_1, n_2, \dots, n_p$ avec $n_1 + n_2 + \dots + n_p = N$. On peut définir les **fréquences** correspondantes :

Pour $1 \leq i \leq p$, $f_i = \frac{n_i}{N}$.

Cette fréquence est parfois exprimée en pourcentage.

Définition 1.4: Effectifs cumulés croissants, fréquences cumulées croissantes

- ★ **L'effectif cumulé croissant** d'une valeur est la somme des effectifs des valeurs inférieures ou égales à cette valeur,
- ★ **la fréquence cumulée croissante** d'une valeur est la somme des fréquences des valeurs inférieures ou égales à cette valeur.

Propriété 1.5

On a :

- ★ Pour $1 \leq i \leq p$, $0 \leq f_i \leq 1$
- ★ $f_1 + f_2 + \dots + f_p = 1$

Exemple 1

Nous prenons comme **population** les élèves de seconde. Le **caractère** étudié est la note obtenue. C'est un caractère **quantitatif** et **discret** .
La série statistique est 2, 3, 3, 4, 5, 6, 6, 7, 7, 7, 8, 8, 8, 8, 9, 9, 9, 9, 9, 10, 10, 11, 11, 11, 13, 13, 15, 16.

★ On peut choisir d'utiliser les valeurs de 2 à 16 pour calculer les effectifs et les fréquences en pourcentage :

Notes	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	Total
Eff.	1	2	1	1	2	3	5	6	2	3	0	2	0	1	1	30
E.C.C.	1	3	4	5	7	10	15	21	23	26	26	28	28	29	30	30
Fréq. en %	3	7	3	3	7	10	17	20	7	10	0	7	0	3	3	100

A partir des E.C.C (ou des F.C.C), on peut trouver facilement la médiane.

Pour cela on calcule $\frac{1}{2}N = 15$.

Alors, $Me = \frac{y_{15}+y_{16}}{2} = \frac{8+9}{2} = 8.5$

On peut calculer l'étendue de la série : $e(X) = 16 - 2 = 14$.

★ On peut choisir de définir les classes $[0; 2[$, $[2; 4[$, ... , $[18; 20[$ pour calculer les effectifs et les fréquences :

Notes	$[0; 2[$	$[2; 4[$	$[4; 6[$	$[6; 8[$	$[8; 10[$	$[10; 12[$	$[12; 14[$	$[14; 16[$	$[16; 18[$	$[18; 20[$	Total
Eff.	0	3	2	5	11	5	2	1	1	0	30
Fréq.	0	0.1	0.066	0.166	0.366	0.166	0.666	0.333	0.333	0	1
F.C.C	0	0.1	0.166	0.333	0.7	0.866	0.933	0.966	1	1	1

A partir des F.C.C (ou des E.C.C), on peut trouver facilement les quartiles. Pour cela on cherche le passage des 25% et des 75%.

On trouve $Q_1 \in [6; 8[$. Donc $Q_1 = 7$. De même, $Q_2 = 11$

Alors l'intervalle inter-quartile est l'intervalle $[7; 11]$ dont l'écart vaut $11 - 7 = 4$.

Propriété 1.6: Loi des grands nombres

Lorsque la taille de la série (appelé **échantillon**) augmente, alors la fréquence f_i associée à la valeur y_i (respectivement à la classe $[y_i; y_{i+1}[$) se rapproche de la probabilité $P(X = y_i)$ (respectivement $P(y_i \leq X < y_{i+1})$).

Exemple 2

On joue sur une machine d'arcade dont le fonctionnement est inconnu. Soit l'événement A : « on gagne le jeu ». A priori on ne connaît pas la probabilité $P(A)$. Néanmoins, on peut jouer de nombreuses fois et calculer la fréquence de victoires f :

$$f = \frac{\text{nombres de victoires}}{\text{nombres de parties jouées}}$$

Plus on joue de parties, plus la fréquence observée f est proche de la probabilité inconnue $p(A)$.

2 Caractéristiques de position

2.1. Médiane

Définition 2.1: Mediane

Soit une série statistique ordonnée dont les n valeurs sont $x_1 \leq x_2 \leq x_3 \leq \dots \leq x_n$. La **médiane** est un nombre Me qui permet de diviser cette série en deux sous-groupes de même effectif.

- ★ Si l'effectif total $n = 2N + 1$ est **impair**, Me est la valeur de cette série qui est située au milieu, à savoir x_N . On a $x_1 \leq \dots \leq x_{N-1} \leq x_N \leq x_{N+1} \leq \dots \leq x_{2N+1}$.
- ★ Si l'effectif total $n = 2N$ est **pair**, Me est la moyenne des deux valeurs du milieu, à savoir x_N et x_{N+1} . On a $x_1 \leq \dots \leq x_{N-1} \leq Me \leq x_{N+1} \leq \dots \leq x_{2N+1}$ et $Me = \frac{x_N + x_{N+1}}{2}$.

Exemple 3

- ★ La médiane de la série 2, 5, 6, 8, 9, 9, 10 est $Me = 8$.
- ★ La médiane de la série 2, 5, 6, 8, 9, 9 est $Me = 7$.
- ★ La médiane de la série 2, 5, 6, 6, 9, 10 est $Me = 6$.

2.2. Quartiles

Définition 2.2: Quartile

Soit une série statistique, on appelle **quartiles** de la série un triplet de réels $(Q_1 ; Q_2 ; Q_3)$ qui sépare la série en quatre groupes de même effectif.

Par définition, le deuxième quartile Q_2 est égal à la médiane $Me(X)$.

On peut obtenir les valeurs de Q_1 , Me et Q_3 avec un tableur ou la calculatrice.

Exemple 4

Pour la série étudiée, la calculatrice nous donne $Q_1 = 7$, $Me = 8,5$ et $Q_3 = 10$.

2.3. Moyenne pondérée

Définition 2.3: Moyenne

La **moyenne** est le centre d'une série statistique, en prenant en compte les valeurs elle-même (et pas uniquement l'ordre comme la médiane).

Soit une série statistique de N valeurs $x_1, x_2, \dots, x_N$. La moyenne m (parfois notée $\bar{x}$) est le nombre :

$$m = \bar{x} = \frac{x_1 + x_2 + \dots + x_N}{N} = \frac{1}{N} \sum_{i=1}^N x_i$$

Lorsque l'on a p valeurs différentes $y_1, y_2, \dots, y_p$ d'effectifs associés $n_1, n_2, \dots, n_p$ avec $n_1 + n_2 + \dots + n_p = N$, alors le calcul devient :

$$m = \bar{x} = \frac{x_1 + x_2 + \dots + x_N}{N} = \frac{n_1 y_1 + n_2 y_2 + \dots + n_p y_p}{N} = \frac{1}{N} \sum_{i=1}^p n_i y_i$$

Remarques :

- ★ On appelle cette moyenne une **moyenne pondérée** car on affecte à chaque valeur y_i un « poids » n_i correspondant à la fréquence, c'est-à-dire l'importance de la valeur y_i dans le calcul.
- ★ Lorsque la série est regroupée en classes, on calcule la moyenne en prenant le **centre de chaque classe**. Le centre de la classe $[y_i ; y_{i+1}[$ est $c = \frac{y_i + y_{i+1}}{2}$.

Exemple 5

★ Dans la **série A**, la moyenne du contrôle est égale à

$$\bar{x} = \frac{2 \times 1 + 3 \times 2 + \dots + 16 \times 1}{30} = \frac{254}{30} \approx 8,47$$

★ si on regroupe par classe d'amplitude 2 points, une estimation de la moyenne est :

$$\bar{x} = \frac{0 \times 1 + 3 \times 3 + 2 \times 5 + \dots + 0 \times 19}{30} = \frac{266}{30} \approx 8,86$$

**Remarque :**

On peut aussi calculer une moyenne à partir de la distribution de fréquences :

$$\bar{x} = f_1x_1 + f_2x_2 + \dots + f_px_p = \sum_{i=1}^p f_i x_i.$$

3 Caractéristiques de dispersion

Définition 3.1: Etendue

On appelle **étendue** d'une série discrète X le réel défini par $e(X) = \max(X) - \min(X)$.

Il s'agit de la première mesure de la dispersion d'une série statistique. Son principal mérite a longtemps été d'exister, et de fournir une information sur la dispersion très simple à obtenir.

3.1. L'écart interquartile

Définition 3.2: Ecart inter-quartiles

On appelle **intervalle inter-quartiles** l'intervalle $[Q_1 ; Q_3]$.

L'amplitude de cet intervalle est appelée **écart inter-quartiles**. Cette valeur est l'indicateur de dispersion associé à la médiane.

3.2. L'écart type

Définition 3.3: Ecart-type

L'écart type, noté σ , est un indicateur de dispersion associé à la moyenne : il mesure la dispersion des valeurs autour de la moyenne. Plus l'écart-type est grand, plus les valeurs sont dispersées et moins la moyenne représente de façon significative la série.

On peut obtenir l'écart-type σ avec un tableur ou la calculatrice.

**Remarque :**

La connaissance des formules qui suivent sont facultatives

Il est possible de définir de manière rigoureuse l'écart type :

- L'écart type σ de la série statistique est défini comme la racine carrée de la variance V .

$$\sigma = \sqrt{V}$$

- La variance de la série statistique est :

$$V = \frac{n_1(x_1 - \bar{x})^2 + \dots + n_k(x_k - \bar{x})^2}{N}$$

La variance est aussi appelée la moyenne quadratique de la série centrée.

4 Représentation graphique d'une série statistique


4.1. Histogramme

Lorsque le caractère étudié est **quantitatif** et lorsque les modalités sont regroupées en **classes**, on peut représenter la série par un **histogramme** : l'aire de chaque rectangle est alors proportionnelle à l'effectif (ou à la fréquence) associée à chaque classe.

Lorsque les classes ont la même **amplitude**, c'est la hauteur qui est proportionnelle à l'effectif.


Exemple 6

Histogramme de la **série A** pour laquelle les amplitudes sont toutes égales à 5 :



Exemple 7

Exemple d'un histogramme représentant la répartition des salaires dans une entreprise, l'amplitude des classes n'étant pas régulières :



On obtient le tableau suivant :


Salaires	[900; 1200]	[1200; 1400]	[1400; 1600]	[1600; 1800]	[1800; 2000]	[2000; 2400]
Effectif	30	30	60	40	20	10

4.2. Nuage de points

Lorsque le caractère étudié est **quantitatif et discret**, on peut représenter la série par un **nuage de points** : chaque couple de valeurs est représenté par un point dans un repère orthogonal.

Exemple 8

Nuage de points de la **série A** :




4.3. Courbe des fréquences cumulées

Enfin, Lorsque le caractère étudié est **quantitatif** et lorsque les modalités sont regroupées en **classes**, on peut effectuer la **courbe des fréquences cumulées** (croissantes ou décroissantes) appelée aussi **polygone** des fréquences cumulées.

Exemple 9

Polygone des fréquences cumulées croissantes et décroissantes de la **série A** :



On peut grâce à ces polygones déterminer une médiane de la série de deux manières :

- ★ Soit en déterminant le point du polygone d'ordonnée 50% : on trouve environ $Me = 8,2$,
- ★ soit en lisant l'abscisse du point d'intersection des deux courbes.

5 Médiane, quartile et représentations graphiques associées

Dans la partie précédente, on a réussi à déterminer graphiquement une médiane d'une série statistique à caractère quantitatif continu.

En effet, il n'est pas possible pour ce type de série de la faire analytiquement. Cependant pour les série à caractère quantitatif discret, il est tout a fait possible de le faire "à la main".

5.1. Calcul de médiane et de quartiles

Exemple 10

Les résultats d'une enquête sur le prix d'une baguette de pain dans 30 boulangeries d'une ville sont regroupés dans le tableau suivant.

Prix (en centimes d'euros)	70	75	80	85	90	95	100	105	110	115	120	Total
Nombres de boulangerie	1	1	2	4	7	3	3	4	2	2	1	30

Méthode

[Calcul de la médiane (avec N pair)]

L'effectif total de la série statistiques est de 30 donc N est pair.

Une fois les valeurs de la série statistique triées par ordre croissant, une médiane est donc la moyenne des deux valeurs du milieu.

- La première valeur du milieu est la valeur située à la position $\frac{30}{2} = 15$
- La deuxième valeur du milieu est la valeur située à la position $\frac{30}{2} + 1 = 16$

Pour pouvoir trouver facilement quelle valeur se situe en position 15 et 16, il faut dresser le tableau des Effectifs cumulés croissants (E.c.c.).

Prix (en centimes d'euros)	70	75	80	85	90	95	100	105	110	115	120	Total
Nombres de boulangerie	1	1	2	4	7	3	3	4	2	2	1	30
E.c.c.	1	2	4	8	15	18	21	25	27	29	30	X

La 15^e valeur de la série vaut donc 90 et la 16^e valeur vaut 95.

On fait la moyenne de la 15^e valeur et la 16^e valeur pour obtenir la médiane :

$$\begin{aligned} Me &= \frac{90 + 95}{2} \\ &= 92.5 \end{aligned}$$

La médiane de cette série statistique est de 92.5 centimes.

On peut en conclure que la moitié des baguettes de pain de la ville coute 92.5 centimes ou moins.

Méthode

[Calcul des quartiles]

L'effectif total de la série statistique est de 30.

- Le premier quartile est la première valeur située au delà de la position $\frac{1}{4} \times 30 = 7.5$ donc la 8^e valeur.
- Le troisième quartile est la première valeur située au delà de la position $\frac{3}{4} \times 30 = 22.5$ donc la 23^e valeur.

Pour pouvoir trouver facilement quelles valeurs se situent en position 8 et 23, on reprend le tableau des Effectifs cumulés croissants (E.c.c.).

Prix (en centimes d'euros)	70	75	80	85	90	95	100	105	110	115	120	Total
Nombres de boulangerie	1	1	2	4	7	3	3	4	2	2	1	30
E.c.c.	1	2	4	8	15	18	21	25	27	29	30	X

Donc le premier quartile Q_1 vaut 85 et Q_3 vaut 105.

On peut en conclure qu'au moins un quart des baguettes de pain ont un prix inférieur à 85 centimes d'euros et au moins 75% des baguettes ont un prix inférieur à un euros et cinq centimes

On peut aussi calculer la valeur de l'écart interquartile :

$$Q_3 - Q_1 = 105 - 85 = 20$$


On peut en conclure que la moitié des baguettes de pain sont dans une fourchette de prix de 20 centimes d'euros

5.2. Représentation graphique associée à la médiane et aux quartiles

Les valeurs extrêmes (minimum et maximum), la médiane et les deux quartiles permettent de partager une série en quatre parties contenant chacune environ un quart de l'effectif total. On a ainsi une idée de la répartition des valeurs de cette série.

Méthode : Construction du diagramme en boîte

- ★ Tracer un axe qui **doit** être gradué en fonction de la série statistique étudiée.
- ★ La « boîte » est limitée par Q_1 et Q_3 . Sa longueur est $Q_3 - Q_1$
- ★ Elle montre la médiane Me .
- ★ Les « moustaches » sont limitées par les valeurs extrêmes.




Exemple 11

En reprenant l'étude fait sur nos boulangeries ci-dessus, on a :

- $Q_1 = 85$ et $Q_3 = 105$
- $Me = 92.5$
- $Min = 70$ et $Max = 120$

Le diagramme en boîte de cette série statistique est donc :



Remarque :

Il est souvent intéressant de tracer le diagramme en boîte de deux séries statistiques différentes sur le **même** axe gradué, afin de pouvoir mieux les comparer.